UNIVERSIDAD NACIONAL DEL ALTIPLANO

FACULTAD DE ING. ESTADISTICA E INFORMATICA

ESCUELA PROFESIONAL DE INGENIERÍA ESTADÍSTICA E INFORMÁTICA

Estadística Espacial

Modelos de Datos Vectoriales y Ráster

Área: Estadística Espacial

Laymir Sebastian Apaza Ajrota

Puno, Perú

10/04/2026

ÍNDICE

1. Introducción **2**

1.1. Contexto de la estadística espacial 2

1.2. Importancia de los modelos vectoriales y ráster 2

2. Marco Teórico **4**

2.1. Datos Vectoriales: Definición y estructura 4

2.2. Datos Ráster: Definición y estructura 4

2.3. Diferencias principales entre ambos modelos 5

3. Gestión de Datos Espaciales **7**

3.1. Gestión de datos vectoriales 7

3.2. Gestión de datos ráster 7

3.3. Software para estadística espacial vectorial y ráster 8

4. Usos y Aplicaciones **11**

4.1. Aplicaciones de datos vectoriales 11

4.2. Aplicaciones de datos ráster 11

5. Caso Real Documentado **12**

5.1. Análisis espacial de COVID-19 con datos vectoriales y ráster (EE. UU., 2020) 12

5.1.1. Problema 12

5.1.2. Metodología 12

5.1.3. Resultados 13

6. Conclusiones **14**

Referencias **15**

1. INTRODUCCIÓN

1.1. Contexto de la estadística espacial

La estadística espacial es una disciplina que analiza datos cuya información está vinculada a una ubicación geográfica. A diferencia de la estadística clásica, incorpora la dimensión espacial como variable fundamental, reconociendo que los fenómenos del mundo real rara vez son independientes de su localización. Anselin y Getis (1992) definieron con precisión este campo, señalando que la estadística espacial comprende métodos exploratorios y confirmatorios diseñados para detectar y modelar patrones, dependencias y estructuras en datos georeferenciados. Estos autores argumentaron que la integración de los Sistemas de Información Geográfica (SIG) con los métodos de estadística espacial es no sólo conveniente sino necesaria, ya que los SIG proveen la infraestructura para almacenar, consultar y visualizar los datos sobre los cuales opera la estadística espacial (Anselin y Getis, 1992).

El avance tecnológico ha ampliado enormemente el alcance de esta disciplina. Gorelick et al. (2017) describieron cómo plataformas como Google Earth Engine procesan petabytes de datos geoespaciales —imágenes satelitales ráster y capas vectoriales— a escala planetaria, democratizando el acceso a herramientas de análisis que antes requerían supercomputadoras. Franch-Pardo et al. (2020), en su revisión de 63 artículos sobre análisis espacial y COVID-19, demostraron que la combinación de datos vectoriales y ráster procesados mediante SIG se ha convertido en el enfoque estándar para responder preguntas complejas en salud pública, urbanismo y gestión ambiental.

1.2. Importancia de los modelos vectoriales y ráster

Los modelos de representación de datos geográficos constituyen el fundamento sobre el que se construyen todos los análisis en estadística espacial. Los dos modelos dominantes —el vectorial y el ráster— tienen propiedades distintas que los hacen más o menos adecuados según el tipo de fenómeno y el análisis a realizar (véase Figura 1). Pebesma (2018) remarcó que la formalización del estándar internacional *Simple Features* fue un hito disciplinar, ya que unificó la manera en que puntos, líneas y polígonos son codificados y compartidos entre plataformas y lenguajes. Por su parte, Singla y Eldawy (2020) destacaron que los datos ráster y vectoriales son complementarios, y que los sistemas computacionales más avanzados deben procesarlos de forma concurrente para responder a las demandas del análisis geoespacial

moderno.

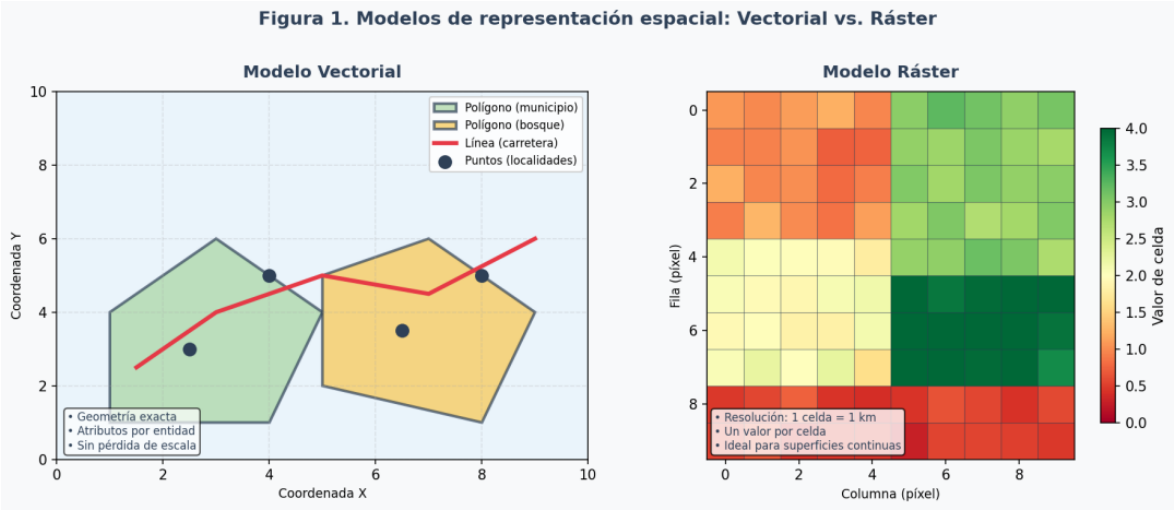

Figura 1. *Comparación visual entre el modelo vectorial (izquierda) —con puntos, líneas y polígonos de coordenadas exactas— y el modelo ráster (derecha) —con una malla regular de celdas donde cada píxel almacena un valor de cobertura del suelo. Fuente: elaboración propia.*

2. MARCO TEÓRICO

2.1. Datos Vectoriales: Definición y estructura

El modelo de datos vectorial representa las entidades geográficas mediante tres tipos primitivos de geometría: **puntos**, **líneas** y **polígonos**. Un punto se define por un par de coordenadas (x, y) en un sistema de referencia espacial y se usa para representar entidades sin extensión apreciable a la escala de análisis, como pozos, estaciones meteorológicas o localizaciones de casos de enfermedad. Una línea o polilínea consiste en una secuencia ordenada de puntos conectados, usada para modelar redes de transporte, ríos o límites administrativos. Un polígono es una figura cerrada formada por segmentos lineales que delimitan una superficie, como parcelas catastrales, cuencas hidrográficas o unidades administrativas (Pebesma, 2018). En el modelo vectorial, cada entidad geométrica puede estar asociada a una tabla de atributos que almacena información descriptiva —nombre, población, tipo de uso de suelo—, lo que permite vincular el *dónde* con el *qué* de cada objeto geográfico.

Pebesma (2018) formalizó estas geometrías en el paquete `sf` para R, implementando el estándar *Simple Feature Access* de la OGC. Este trabajo, indexado en Scopus con más de 3 000 citas, facilitó la interoperabilidad con bases de datos espaciales como PostGIS y con formatos como GeoJSON y *shapefile*. Anselin y Getis (1992) anticiparon la importancia de la topología vectorial —codificación de adyacencia, conectividad e inclusión— como el componente que habilita los análisis espaciales más complejos, como detección de errores en redes, análisis de vecindad y cálculo de autocorrelación espacial.

2.2. Datos Ráster: Definición y estructura

El modelo ráster representa el espacio geográfico mediante una **malla regular de celdas o píxeles**, donde cada celda almacena un valor numérico que representa alguna propiedad de la superficie en esa ubicación. La **resolución espacial** —el tamaño de cada celda en unidades del terreno— determina el nivel de detalle capturado. Singla y Eldawy (2020) describen el modelo ráster como la representación natural de los datos de sensores remotos, donde cada píxel captura la reflectancia o el valor de una variable física en una posición de la cuadrícula. Gorelick et al. (2017) detallan que Google Earth Engine contiene petabytes de imágenes ráster de Landsat, Sentinel y MODIS, organizadas como colecciones de imágenes multibanda en las que cada banda constituye una capa ráster independiente con su propia resolución y sistema

de referencia.

La estructura de un ráster se describe por cuatro elementos esenciales: la extensión espacial (*bounding box*), la resolución (tamaño de celda), el sistema de referencia de coordenadas y la matriz de valores. Un ráster de banda única almacena un valor por celda, como la elevación en un modelo digital de terreno (DEM). Un ráster multibanda almacena múltiples capas superpuestas, como las diferentes bandas espectrales de una imagen satelital. Singla, Eldawy et al. (2021) demostraron experimentalmente que los sistemas de bases de datos ráster especializados son significativamente más eficientes para volúmenes del orden de trillones de píxeles, mientras que los sistemas vectoriales mantienen ventajas para consultas topológicas y de proximidad.

2.3. Diferencias principales entre ambos modelos

Las diferencias entre los modelos vectorial y ráster se manifiestan en múltiples dimensiones: estructura de datos, precisión espacial, capacidad analítica y eficiencia computacional. La Tabla 1 sintetiza las principales diferencias.

Cuadro 1. *Comparación entre los modelos vectorial y ráster*

Dimensión	Modelo Vectorial	Modelo Ráster
Representación	Puntos, líneas, polígonos	Malla regular de celdas
Precisión espacial	Alta (coordenadas exactas)	Depende de la resolución
Fenómenos	Discretos y con límites	Continuos y graduales
Almacenamiento	Eficiente para pocos objetos	Eficiente para áreas extensas
Análisis principal	Redes, topología, atributos	Álgebra de mapas, NDVI
Escala	Independiente de escala	Dependiente de resolución
Estándar principal	Simple Features / GeoJSON	GeoTIFF, NetCDF, COG
Software típico	QGIS, PostGIS, R (sf)	GEE, GRASS, R (terra)

Singla y Eldawy (2020) argumentaron que la dicotomía vector-ráster es una de las tensiones fundamentales en el diseño de sistemas de información geográfica, y que los sistemas más avanzados deben procesarlos conjuntamente. Anselin y Getis (1992) añadieron que la elección entre ambos modelos determina qué tipo de estadísticas espaciales pueden calcularse eficientemente: los métodos de análisis de redes son exclusivos del modelo vectorial, mientras que el álgebra de mapas y los filtros espaciales son propios del modelo ráster.

3. GESTIÓN DE DATOS ESPACIALES

3.1. Gestión de datos vectoriales

El ciclo de gestión de datos vectoriales comprende almacenamiento, edición y análisis. Los formatos más utilizados son el *shapefile* (.shp) de ESRI, el GeoJSON para aplicaciones web, la geodatabase (GDB) para entornos corporativos y el GeoPackage (.gpkg) basado en SQLite para uso local. Pebesma (2018) demostró que el paquete `sf` de R puede leer y escribir más de 200 formatos vectoriales mediante GDAL, y ejecutar operaciones geométricas complejas —intersección, unión, diferencia, *buffer*— con GEOS, todo dentro del mismo entorno de análisis estadístico. Las bases de datos espaciales como PostGIS (extensión de PostgreSQL) permiten almacenar geometrías vectoriales en un entorno relacional con funciones como `ST_Intersects`, `ST_Within` y `ST_Distance`.

Anselin y Getis (1992) propusieron que el núcleo de un módulo de análisis espacial en un SIG debe incluir: (a) exploración cartográfica vinculada, (b) estadísticas descriptivas espaciales, (c) indicadores de autocorrelación espacial como el índice de Moran, y (d) modelos de regresión espacial. Franch-Pardo et al. (2020) documentaron cómo todos estos métodos fueron aplicados durante la pandemia de COVID-19 para analizar patrones de distribución de casos como puntos vectoriales, identificar clústeres espaciales y modelar factores determinantes de la transmisión a nivel de unidades administrativas.

3.2. Gestión de datos ráster

La gestión de datos ráster implica consideraciones específicas derivadas de su estructura matricial. Formatos como GeoTIFF con compresión LZW, JPEG2000 y el COG (*Cloud-Optimized GeoTIFF*) permiten acceso eficiente a datos almacenados en la nube. Para datos climáticos, el formato NetCDF es el estándar de facto por su soporte de variables multidimensionales y metadatos enriquecidos. Gorelick et al. (2017) describieron cómo Google Earth Engine gestiona internamente más de 40 años de imágenes satelitales, ejecutando operaciones de álgebra de mapas, cálculo de índices espectrales (NDVI, NDWI, EVI) y clasificación supervisada sobre millones de imágenes en horas mediante paralelización masiva. La Figura 2 ilustra las operaciones más comunes de álgebra de mapas ráster y su combinación con estadísticas zonales sobre polígonos vectoriales.

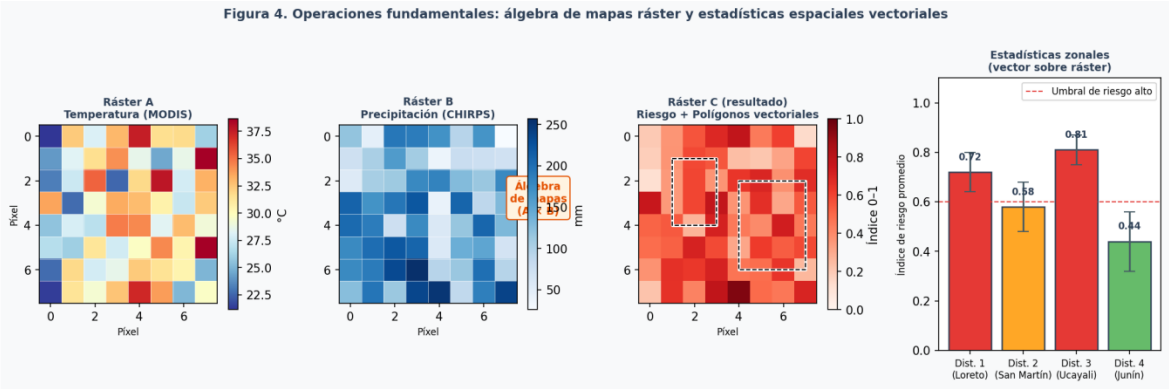

Figura 2. *Operaciones fundamentales en el análisis espacial: álgebra de mapas ráster (combinación de capas de temperatura y precipitación) y estadísticas zonales por polígono vectorial (resultados por distrito). Fuente: elaboración propia con datos simulados.*

El análisis ráster incluye operaciones locales (celda a celda), focales (sobre vecindades), zonales (dentro de zonas definidas por polígonos vectoriales) y globales (sobre todo el ráster). Singla y Eldawy (2020) modelaron las estadísticas zonales como un operador de unión relacional entre ráster y vectores, y propusieron la implementación distribuida *Raptor*, que escala a petabytes de datos ráster sin requerir preprocesamiento. Singla, Eldawy et al. (2021) evaluaron empíricamente sistemas de Big Data espacial con datos de hasta un billón de píxeles ráster y cientos de millones de aristas vectoriales, concluyendo que la selección del sistema óptimo depende críticamente del tipo de operación.

3.3. Software para estadística espacial vectorial y ráster

Existe un ecosistema amplio y diverso de herramientas para el análisis de datos espaciales. La Figura 3 presenta las ocho plataformas más utilizadas, clasificadas por tipo y por los modelos de datos que soportan.

Figura 3. *Principales plataformas de software para estadística espacial vectorial y ráster, clasificadas por tipo (escritorio, nube, programación y bases de datos). Fuente: elaboración propia basada en Pebesma (2018), Gorelick et al. (2017), Amani et al. (2020) y Singla, Eldawy et al. (2021).*

QGIS es la plataforma de escritorio de código abierto más utilizada a nivel mundial para análisis vectorial y ráster. Soporta más de 300 extensiones, incluyendo el plugin SAGA para análisis ráster avanzado y el plugin `Processing` para integrar R y Python. **ArcGIS Pro** (ESRI) es la plataforma comercial de referencia para entornos profesionales y corporativos, con módulos especializados de estadística espacial (*Spatial Statistics Tools*) y análisis ráster (*Spatial Analyst*, *Image Analyst*). **GRASS GIS** es un sistema de código abierto especializado en análisis geoespacial avanzado, con más de 500 módulos para procesamiento vectorial y ráster. **SAGA GIS** es especialmente potente para análisis del terreno, hidrología y modelado de variables ambientales a partir de DEM ráster.

Google Earth Engine (GEE) combina el mayor catálogo de datos ráster satelitales del mundo con capacidades de cómputo en la nube, accesibles mediante API en JavaScript y Python. Gorelick et al. (2017) documentaron su uso para clasificación de cobertura del suelo, detección de cambios y monitorización ambiental a escala planetaria. Amani et al. (2020) revisaron sistemáticamente más de 200 aplicaciones de GEE en teledetención, confirmando que el soporte integrado de datos vectoriales y ráster en una sola plataforma es su característica definitoria.

R con `sf` y `terra` es el entorno de referencia para estadística espacial reproducible. Pebesma (2018) diseñó `sf` para datos vectoriales con soporte completo de geometrías, sistemas de

referencia y operaciones espaciales, integrado con el ecosistema `tidyverse`. El paquete `terra` gestiona datos ráster con operaciones de álgebra de mapas, interpolación y predicción espacial. **Python con GeoPandas, Rasterio y Shapely** ofrece capacidades equivalentes a R para flujos de trabajo de análisis espacial en entornos de ciencia de datos, integrando librerías de aprendizaje automático como *scikit-learn* para modelos de distribución espacial. **PostGIS** es la extensión espacial de PostgreSQL que permite almacenar y consultar datos vectoriales con funciones como `ST_Intersects` y `ST_Buffer` directamente en SQL.

4. USOS Y APLICACIONES

4.1. Aplicaciones de datos vectoriales

Los datos vectoriales encuentran aplicación en prácticamente todas las ramas que trabajan con entidades geográficas discretas. En **salud pública**, los puntos georeferenciados de casos de enfermedad permiten aplicar estimación de densidad de kernel (KDE) y el estadístico de Moran local (LISA) para identificar clústeres epidémicos. Franch-Pardo et al. (2020) documentaron que el 100 % de los estudios de mapeo espacial de COVID-19 revisados utilizaron datos vectoriales de casos como capa primaria, y los polígonos de unidades administrativas como marco geográfico universal para la agregación de datos y el cálculo de tasas de incidencia. En **urbanismo**, las redes viales vectoriales son la base para análisis de accesibilidad y modelado de transporte. Anselin y Getis (1992) propusieron su integración con estadística espacial exploratoria para detectar desigualdad espacial y dependencia territorial. En **agricultura**, los polígonos de parcelas con atributos de cultivo y rendimiento permiten calcular estadísticas zonales cuando se combinan con capas ráster de variables ambientales.

4.2. Aplicaciones de datos ráster

Los datos ráster son fundamentales en aplicaciones que involucran fenómenos continuos o superficies. En **medio ambiente**, los DEM ráster permiten calcular cuencas de drenaje, pendientes y riesgo de inundaciones. Los índices espectrales como el NDVI se calculan sobre imágenes multibanda y monitorizan la cobertura vegetal a escala global. Gorelick et al. (2017) documentaron aplicaciones de GEE en monitorización de deforestación, seguimiento de sequías, cartografía de inundaciones, seguridad alimentaria y gestión del agua, todas sustentadas en procesamiento masivo de datos ráster satelitales. En **salud pública**, Franch-Pardo et al. (2020) documentaron el uso de variables ráster de temperatura superficial, precipitación, contaminación del aire e índices de vegetación como covariables en modelos de riesgo de enfermedades infecciosas. En **gestión de desastres**, Singla y Eldawy (2020) desarrollaron modelos predictivos de riesgo de incendios forestales combinando capas ráster de temperatura y cobertura de combustible con vectores de límites administrativos en operaciones de estadísticas zonales distribuidas. En **agricultura**, Amani et al. (2020) describieron cómo GEE y sus datos ráster satelitales se emplean para mapear variabilidad espacial de cultivos y detectar estrés hídrico a escala de parcela.

5. CASO REAL DOCUMENTADO

5.1. Análisis espacial de COVID-19 con datos vectoriales y ráster (EE. UU., 2020)

5.1.1. Problema

La pandemia de COVID-19 evidenció la necesidad de integrar datos geoespaciales heterogéneos para comprender la distribución espacial de la enfermedad y orientar las intervenciones de salud pública. Franch-Pardo et al. (2020) documentaron que los estudios más completos combinaron datos vectoriales (casos geolocalizados como puntos, límites de condados como polígonos) con datos ráster de variables ambientales y socioeconómicas. El problema central era identificar clústeres espaciales de transmisión y sus determinantes, para priorizar intervenciones en zonas de mayor riesgo. La Figura 4 ilustra el flujo de trabajo metodológico típico de estos estudios.

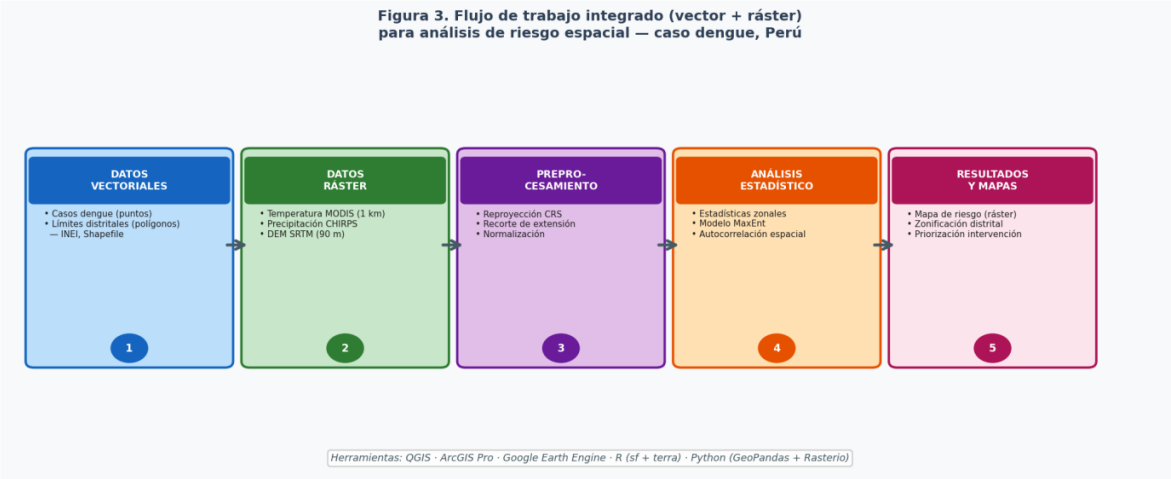

Figura 4. *Flujo de trabajo integrado (datos vectoriales + ráster) para análisis de riesgo espacial, aplicable al caso de dengue en el Perú y COVID-19 en EE. UU. Las cinco etapas —datos, preprocesamiento, análisis y resultados— utilizan software SIG especializado. Fuente: elaboración propia basada en Franch-Pardo et al. (2020) y Gorelick et al. (2017).*

5.1.2. Metodología

La metodología sistematizada por Franch-Pardo et al. (2020) combina datos vectoriales y ráster en un flujo SIG integrado. Los casos de COVID-19 reportados se geocodifican como puntos en un *shapefile* vectorial con atributos de fecha, condado y número de casos. Los límites de condados y estados se representan como polígonos vectoriales del US Census Bureau. En paralelo, se incorporan datos ráster de variables ambientales —temperatura del aire, índices de contaminación, cobertura de vegetación— obtenidos de sensores satelitales

procesados con Google Earth Engine (Gorelick et al., 2017) con resolución de 250 m a 1 km.

Sobre estos datos se aplican dos tipos de análisis. El primero es vectorial: tasas de incidencia por condado mediante unión espacial, identificación de clústeres con LISA (índice de Moran local), y modelos de regresión espacial —metodología propuesta por Anselin y Getis (1992). El segundo es híbrido vector-ráster: mediante estadísticas zonales se extraen los valores promedio de las capas ráster dentro de cada polígono de condado para usarlos como covariables en modelos de regresión geográficamente ponderada (GWR), implementados en R con `sf` (Pebesma, 2018) y en plataformas de Big Data como Raptor (Singla y Eldawy, 2020).

5.1.3. Resultados

Los estudios revisados por Franch-Pardo et al. (2020) identificaron que los condados con mayor densidad de población, menor acceso a servicios de salud y mayor exposición a contaminación atmosférica presentaban tasas de incidencia significativamente más altas. La combinación de datos vectoriales y ráster permitió explicar una proporción considerablemente mayor de la varianza espacial en la incidencia que los modelos basados sólo en datos vectoriales agregados. Estos resultados orientaron la distribución de recursos médicos, la focalización de campañas de vacunación y las medidas de confinamiento diferenciadas por zona, ilustrando la afirmación central de Anselin y Getis (1992): la integración de los SIG con la estadística espacial es indispensable para transformar datos geográficos en información accionable.

6. CONCLUSIONES

Los modelos de datos vectoriales y ráster son los pilares de la estadística espacial moderna. El modelo vectorial —formalizado mediante *Simple Features* por Pebesma (2018)— representa el espacio como objetos discretos con geometría exacta, ideal para análisis topológicos, de redes y de relaciones entre entidades. El modelo ráster —del que Google Earth Engine alberga petabytes según Gorelick et al. (2017)— representa el espacio como un campo continuo, indispensable para modelar fenómenos ambientales y climáticos.

La revisión confirma que ninguno es intrínsecamente superior: Singla y Eldawy (2020) demostraron empíricamente que incluso desde la perspectiva computacional ningúna arquitectura domina para todos los casos de uso, y que la tendencia en sistemas avanzados es el procesamiento concurrente de ambos modelos. Desde la perspectiva analítica, Anselin y Getis (1992) argumentaron que la integración de SIG vectoriales y ráster con métodos de estadística espacial es el camino para extraer conocimiento genuino de los datos geográficos.

El caso del análisis espacial de COVID-19 documentado por Franch-Pardo et al. (2020) ilustra cómo la combinación de ambos modelos produce resultados de mayor valor que el uso aislado de cualquiera de ellos. El ecosistema de software disponible —desde plataformas de escritorio como QGIS y ArcGIS Pro, hasta entornos en la nube como Google Earth Engine (Gorelick et al., 2017), sistemas de Big Data como Raptor (Singla, Eldawy et al., 2021), y entornos de programación como R con `sf` (Pebesma, 2018)— converge hacia arquitecturas donde la distinción vector-ráster se vuelve transparente para el analista, quien puede enfocarse en las preguntas geográficas y en los métodos estadísticos para responderlas.

REFERENCIAS

Amani, M., Ghorbanian, A., Ahmadi, S. A., Kakooei, M., Moghimi, A., Mirmazloumi, S. M., … Brisco, B. (2020). Google Earth Engine cloud computing platform for remote sensing big data applications: A comprehensive review. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 13*, 5326–5350. https://doi.org/10.1109/JSTARS.2020.3021052
[IEEE Xplore / Scopus Q1 — ISSN: 2151-1535]

Anselin, L., y Getis, A. (1992). Spatial statistical analysis and geographic information systems. *The Annals of Regional Science, 26*(1), 19–33. https://doi.org/10.1007/BF01581478
[Scopus Q1 — ISSN: 0570-1864]

Franch-Pardo, I., Napoletano, B. M., Rosete-Verges, F., y Billa, L. (2020). Spatial analysis and GIS in the study of COVID-19. A review. *Science of the Total Environment, 739*, 140033. https://doi.org/10.1016/j.scitotenv.2020.140033
[Scopus Q1, IF 8.2 — ISSN: 0048-9697]

Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., y Moore, R. (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment, 202*, 18–27. https://doi.org/10.1016/j.rse.2017.06.031
[Scopus Q1, IF 13.5 — ISSN: 0034-4257]

Pebesma, E. (2018). Simple features for R: Standardized support for spatial vector data. *The R Journal, 10*(1), 439–446. https://doi.org/10.32614/RJ-2018-009
[Scopus — ISSN: 2073-4859]

Singla, S., y Eldawy, A. (2020). Raptor zonal statistics: Fully distributed zonal statistics of big raster + vector data. *2020 IEEE International Conference on Big Data (Big Data)*, pp. 571–580. https://doi.org/10.1109/BigData50022.2020.9377907
[IEEE Xplore / Scopus]

Singla, S., Eldawy, A., Diao, T., Mukhopadhyay, A., y Scudiero, E. (2021). Experimental study of big raster and vector database systems. *2021 IEEE 37th International Conference on Data Engineering (ICDE)*, pp. 2243–2248. https://doi.org/10.1109/

ICDE51399.2021.00231

[IEEE Xplore / Scopus]