

Integración de índices de vegetación y variables locales mediante estadística espacial y Kriging en la región Puno, 2020–2025

Apaza Ajrota Laymir Sebastian¹, Mamani Vilca Diana Yuliza¹, Mamani Ari Clever Joel¹ y Ccopa Mamani Ana Rebeca^{1,*}

¹Escuela Profesional de Ingeniería Estadística e Informática, Universidad Nacional del Altiplano, Puno, Perú

Resumen

La variabilidad espacial de la cobertura vegetal en el departamento de Puno responde a fuertes gradientes altitudinales, climáticos y ecológicos que condicionan la agricultura, la ganadería y la disponibilidad de humedad superficial. El objetivo de este estudio fue integrar los índices satelitales NDVI, SAVI, EVI y NDMI con precipitación acumulada, temperatura media y altitud, y evaluar sus patrones espacio-temporales mediante estadística espacial e interpolación por Kriging. Se analizaron 17 082 observaciones georreferenciadas distribuidas en las 13 provincias de Puno durante 2020–2025. Los datos de reflectancia procedieron de Sentinel-2, la precipitación de CHIRPS, la temperatura de ERA5-Land y la elevación de SRTM. El procesamiento y el análisis estadístico se desarrollaron en RStudio mediante el lenguaje R. Se aplicaron estadísticos descriptivos, correlación de Pearson, comparación provincial y anual, autocorrelación espacial global mediante el índice de Moran, ajuste de semivariogramas y Kriging ordinario para NDVI, SAVI, EVI y NDMI en 2025. Para cada índice se compararon modelos esférico, exponencial y gaussiano, y el desempeño se evaluó mediante validación cruzada de cinco particiones. El NDVI promedio regional fue 0.325, mientras que el NDMI medio fue -0.033. Los índices se asociaron positivamente con precipitación y temperatura, y negativamente con altitud; el EVI presentó la relación negativa más intensa con la elevación ($r = -0.897$). Sandia y Carabaya concentraron los mayores niveles de vigor vegetal, en contraste con provincias del altiplano sur y central. Todos los índices mostraron autocorrelación espacial positiva y significativa ($p = 0.005$), con valores de Moran entre 0.833 y 0.927. Como resultado representativo, el Kriging ordinario del NDVI alcanzó un RMSE de 0.082 y una correlación observado-predicho de 0.950; el mismo procedimiento fue ejecutado para SAVI, EVI y NDMI. Los resultados evidencian que la integración de variables satelitales y locales permite delimitar zonas ecológicamente diferenciadas y generar superficies continuas útiles para vigilancia ambiental, planificación agrícola y evaluación de sequías en Puno.

Palabras clave: NDVI, SAVI, EVI, NDMI, precipitación, altitud, autocorrelación espacial, semivariograma, Kriging, Puno.

1. Introducción

El monitoreo de la vegetación mediante sensores remotos constituye una herramienta esencial para evaluar la productividad primaria, la disponibilidad de pastos, el estrés hídrico y las transformaciones del territorio. En regiones altoandinas como Puno, la cobertura vegetal se desarrolla bajo condiciones ambientales heterogéneas: extensas mesetas por encima de 3 800 m s.n.m., cuencas lacustres, cadenas montañosas y vertientes orientales que descienden hacia ecosistemas de ceja de selva. Esta diversidad produce contrastes marcados en precipitación, temperatura, humedad y estructura de la vegetación, que no pueden representarse adecuadamente con promedios departamentales únicos.

El NDVI fue desarrollado como un indicador del vigor fotosintético de la vegetación mediante la diferencia normalizada entre la reflectancia del infrarrojo cercano y el rojo [1]. Posteriormente, Huete [2] propuso el SAVI incorporando un factor de ajuste para reducir la influencia del brillo del suelo, especialmente importante en superficies con cobertura vegetal dispersa como las zonas altoandinas. El EVI, por su parte, incorpora correcciones atmosféricas y de fondo que mejoran su desempeño en coberturas densas [3], mientras que el NDMI aproxima el contenido de humedad de la vegetación a partir de la relación entre el infrarrojo cercano y el infrarrojo de onda corta [4]. Estos cuatro índices figuran entre los más utilizados dentro del amplio conjunto de índices espectrales desarrollados para el monitoreo de la vegetación [5].

Sin embargo, los índices satelitales adquieren mayor significado cuando se integran con variables locales. La precipitación influye directamente en la recarga de humedad del suelo y la disponibilidad de agua para la vegetación; la temperatura regula los procesos fisiológicos y la duración del periodo vegetativo; y la altitud resume cambios en presión atmosférica, temperatura, pendiente y exposición. La integración espacial de estos factores permite formular hipótesis sobre los mecanismos que originan los patrones observados y no solo describir su distribución cartográfica.

La estadística espacial es especialmente pertinente porque las observaciones geográficas cercanas tienden a presentar valores semejantes [6, 7]. Ignorar esta dependencia vulnera el supuesto de independencia de la estadística clásica. El índice de Moran cuantifica la autocorrelación espacial global [8], mientras que los semivariogramas describen cómo aumenta la disimilitud con la distancia [7]. A partir de esta estructura de dependencia, el Kriging genera predicciones en ubicaciones no observadas y proporciona una superficie continua que facilita la identificación de gradientes, núcleos de alta vegetación y áreas potencialmente vulnerables [9].

El presente trabajo replica la organización general de un artículo geoespacial compuesto por área de estudio y datos, metodología, resultados y discusión, conclusiones, disponibilidad de datos y referencias, siguiendo el estilo del documento modelo proporcionado por el docente. El propósito fue responder la siguiente pregunta: *¿qué patrones espaciales y temporales presentan los índices NDVI, SAVI, EVI y NDMI en las provincias de Puno, y cómo se relacionan con precipitación, temperatura y altitud durante 2020–2025?*

El objetivo general fue analizar la distribución espacio-temporal de los cuatro índices e integrar variables locales mediante técnicas de estadística espacial y Kriging. Los objetivos específicos fueron: (i) caracterizar la variabilidad de los índices por año y provincia; (ii) estimar la asociación entre los índices y las variables ambientales; (iii) evaluar la autocorrelación espacial global; (iv) modelar la dependencia espacial de NDVI, SAVI, EVI y NDMI mediante semivariogramas; y (v) producir y validar superficies interpoladas para 2025.

2. Área de estudio y datos

2.1. Área de estudio

El departamento de Puno se localiza en el sureste del Perú y comprende 13 provincias: Azángaro, Carabaya, Chucuito, El Collao, Huancané, Lampa, Melgar, Moho, Puno, San Antonio de Putina, San Román, Sandia y Yunguyo. El territorio combina zonas del altiplano, áreas lacustres asociadas al lago Titicaca, cordilleras elevadas y provincias orientales con gradientes hacia la Amazonía. Esta configuración es coherente con los mecanismos climáticos descritos para el Altiplano surandino, donde la circulación atmosférica en altura controla en gran medida la variabilidad de la precipitación y la temperatura [10]. La base analizada cubrió aproximadamente desde 68.89° O hasta 71.07° O y desde 13.09° S hasta 17.17° S.




Figura 1: Distribución de las 17 082 observaciones georreferenciadas y gradiente altitudinal del área de estudio.

2.2. Fuentes y estructura de los datos

La base final contiene 17 082 registros sin valores faltantes, con entre 2 846 y 2 848 observaciones por año. Los índices NDVI, SAVI, EVI y NDMI se calcularon a partir de composiciones anuales de Sentinel-2 Level-2A [11]. La precipitación acumulada anual se extrajo de CHIRPS Daily [12], la temperatura media anual de ERA5-Land Monthly Aggregated [13] y la altitud del modelo digital SRTM [14]. Cada registro incluye departamento, provincia, año, longitud, latitud, cuatro índices y tres variables locales.

Cuadro 1: Variables integradas en la base de análisis.

Variable	Tipo/unidad	Interpretación
NDVI	Índice, -1 a 1	Vigor y densidad relativa de vegetación verde.
SAVI	Índice	Vegetación con ajuste por influencia del suelo.
EVI	Índice	Respuesta mejorada en vegetación densa y con corrección atmosférica.
NDMI	Índice, -1 a 1	Humedad relativa de la vegetación y señal de estrés hídrico.
Precipitación	mm/año	Acumulación anual estimada por CHIRPS.
Temperatura	°C	Temperatura media anual a 2 m estimada por ERA5-Land.
Altitud	m s.n.m.	Elevación del terreno derivada de SRTM.

3. Metodología

3.1. Preprocesamiento y control de calidad

Se verificaron tipos de datos, coordenadas, duplicados y valores faltantes. Las coordenadas geográficas se mantuvieron en WGS84 para la visualización y se transformaron a UTM zona 19S (EPSG:32719) para los análisis basados en distancia. Se conservaron todos los valores espectrales presentes en la base y se revisaron sus rangos antes del análisis. La comparación temporal se efectuó mediante medias anuales, mientras que la comparación territorial se realizó mediante medias provinciales del periodo completo. Todo el análisis estadístico y espacial se implementó en RStudio, utilizando principalmente los paquetes **tidyverse** para manipulación y resumen, **sf** para geometrías y proyecciones [15], **spdep** para autocorrelación espacial [15], **gstat** para semivariogramas y Kriging [16], y **ggplot2** y **tmap** para visualización cartográfica. El flujo reproducible siguió cinco etapas: limpieza de registros, síntesis provincial y anual, integración estadística con las variables locales, evaluación de autocorrelación espacial y modelación geoestadística de 2025.

3.2. Cálculo e interpretación de índices

Los índices fueron calculados mediante las expresiones:

$$NDVI = \frac{NIR - RED}{NIR + RED}, \quad (1)$$

$$SAVI = (1 + L) \frac{NIR - RED}{NIR + RED + L}, \quad L = 0.5, \quad (2)$$

$$EVI = 2.5 \frac{NIR - RED}{NIR + 6RED - 7.5BLUE + 1}, \quad (3)$$

$$NDMI = \frac{NIR - SWIR}{NIR + SWIR}. \quad (4)$$

El NDVI y el EVI representan vigor fotosintético [1, 3]; el SAVI es apropiado para coberturas ralas frecuentes en el altiplano [2]; y el NDMI complementa la evaluación mediante la humedad de la vegetación [4].

3.3. Estadística descriptiva y asociación con variables locales

Para cada variable se estimaron media, desviación estándar, mínimo, mediana y máximo. La relación lineal entre índices y variables locales se evaluó con el coeficiente de correlación de Pearson:

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}. \quad (5)$$

Estas asociaciones se interpretaron como relaciones descriptivas y no como causalidad, debido a la agregación anual y a la posible colinealidad entre precipitación, temperatura y altitud.

3.4. Autocorrelación espacial global

La dependencia espacial se evaluó mediante el índice de Moran global [8]. Se construyó una matriz de pesos espaciales basada en los ocho vecinos más próximos y se estandarizó por filas, siguiendo el marco general de los procesos espaciales descrito por Cliff y Ord [6]. El estadístico se expresó como:

$$I = \frac{n}{S_0} \frac{\sum_i \sum_j w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_i (x_i - \bar{x})^2}, \quad (6)$$

donde w_{ij} representa la relación de vecindad y $S_0 = \sum_i \sum_j w_{ij}$. La significancia se evaluó mediante la aproximación analítica implementada en la función `moran.test` del paquete `spdep` [15]. Para reducir el consumo de memoria se utilizó una muestra aleatoria reproducible de hasta 2 500 puntos por año e índice. Valores positivos indican agrupamiento de observaciones semejantes, valores próximos a cero sugieren aleatoriedad y valores negativos indican dispersión espacial.

3.5. Semivariograma y modelo teórico

Para cada índice de 2025 se calculó el semivariograma experimental a partir de pares de observaciones [7]:

$$\hat{\gamma}(h) = \frac{1}{2N(h)} \sum_{N(h)} [Z(s_i) - Z(s_i + h)]^2. \quad (7)$$

Se ajustaron modelos esférico, exponencial y gaussiano con efecto pepita, meseta y alcance [9, 17, 18]; el modelo seleccionado fue el que presentó el menor error cuadrático de ajuste (SSErr). El efecto pepita representa variabilidad a escalas inferiores al muestreo y error residual; la meseta aproxima la varianza espacial total; y el alcance indica la distancia a partir de la cual la dependencia espacial se estabiliza.

3.6. Kriging ordinario y validación

El Kriging ordinario estima el valor en una ubicación no observada como combinación lineal ponderada de puntos vecinos [9, 18]:

$$\hat{Z}(s_0) = \sum_{i=1}^n \lambda_i Z(s_i), \quad \sum_{i=1}^n \lambda_i = 1. \quad (8)$$

Los pesos se obtuvieron a partir del modelo de covarianza derivado del semivariograma [17]. Para controlar el costo computacional se utilizó una muestra aleatoria reproducible de hasta 1 800 puntos del año 2025, una malla regular de predicción de 5 km y un máximo de 40 vecinos en cada estimación. La validación cruzada se efectuó con cinco particiones, implementada mediante el paquete `gstat` [16], y se calcularon el error medio (ME), el error absoluto medio (MAE), la raíz

del error cuadrático medio (RMSE) y la correlación observado-predicho:

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (\hat{z}_i - z_i)^2}, \quad (9)$$

$$MAE = \frac{1}{m} \sum_{i=1}^m |\hat{z}_i - z_i|. \quad (10)$$

4. Resultados y discusión

4.1. Caracterización general

La Tabla 2 muestra una marcada heterogeneidad regional. El NDVI promedio fue 0.325 y su desviación estándar 0.256, lo cual evidencia coexistencia de superficies con escasa respuesta vegetal y áreas de alta biomasa. El SAVI y el EVI presentaron medias de 0.202 y 0.213, respectivamente. El NDMI medio fue negativo (-0.033), aunque su máximo alcanzó 0.658, señal de que las condiciones de humedad varían ampliamente entre el altiplano y las vertientes orientales.

Cuadro 2: Estadísticos descriptivos de los índices y variables locales ($n = 17\,082$).

Variable	Media	Desv. estándar	Mínimo	Mediana	Máximo
NDVI	0.325	0.256	-0.671	0.241	0.886
SAVI	0.202	0.145	-0.062	0.152	0.608
EVI	0.213	0.172	-0.135	0.147	0.759
NDMI	-0.033	0.181	-0.692	-0.100	0.658
Precipitación (mm)	1261.539	991.008	295.096	843.068	5607.592
Temperatura (°C)	8.951	5.912	-0.080	7.420	25.984
Altitud (m)	3603.332	1318.984	224.000	4026.000	5536.000

La precipitación media anual fue 1 261.5 mm, con valores que superaron 5 600 mm en sectores orientales. La temperatura media fue 8.95°C y la altitud media 3 603 m s.n.m. La elevada dispersión de estas variables explica por qué un análisis departamental agregado ocultaría diferencias ecológicas relevantes.

4.2. Variación temporal 2020–2025

El NDVI disminuyó de 0.327 en 2020 a 0.313 en 2021 y luego mostró recuperación gradual hasta 0.342 en 2025. El EVI se mantuvo alrededor de 0.21 durante 2020–2023 y aumentó a 0.220 en 2025. El NDMI presentó su valor más bajo en 2023 (-0.047), lo que indica una señal regional de menor humedad relativa de la vegetación en ese año. En 2025 se registró la mayor precipitación media del periodo (1 522.4 mm), coincidiendo con el NDVI más alto.




Figura 2: Evolución de los promedios anuales de NDVI, SAVI, EVI y NDMI.

Cuadro 3: Promedios anuales de índices y variables climáticas.

Año	NDVI	SAVI	EVI	NDMI	Precip. (mm)	Temp. (°C)
2020	0.327	0.202	0.211	-0.030	1056.4	8.99
2021	0.313	0.196	0.210	-0.034	1359.0	8.49
2022	0.320	0.199	0.210	-0.022	1158.7	8.74
2023	0.324	0.199	0.208	-0.047	1221.4	9.14
2024	0.324	0.204	0.218	-0.033	1251.3	9.67
2025	0.342	0.211	0.220	-0.032	1522.4	8.68

La variación interanual es menor que la variación espacial entre provincias, lo que sugiere que el gradiente territorial constituye la fuente dominante de heterogeneidad. No obstante, la recuperación observada en 2025 muestra que los indicadores responden también a condiciones climáticas anuales.

4.3. Contrastes provinciales

Sandia obtuvo el NDVI promedio más alto (0.693), seguido por Carabaya (0.492). Ambas provincias incluyen sectores de menor altitud, mayor temperatura y precipitación, donde la cobertura vegetal es más densa. En el extremo opuesto, Yunguyo presentó un NDVI medio negativo (-0.047), mientras que El Collao, San Román y Puno registraron valores bajos. Estos resultados no deben interpretarse únicamente como ausencia de productividad, pues los cuerpos de agua, suelos expuestos, áreas urbanas y mosaicos de cultivo influyen en las medias espaciales.




Figura 3: Comparación del NDVI medio por provincia para el periodo 2020–2025.

Cuadro 4: Promedios provinciales de índices y variables locales, 2020–2025.

Provincia	NDVI	SAVI	EVI	NDMI	Precip.	Temp.	Altitud
Sandia	0.693	0.411	0.462	0.195	2268.3	16.79	1741
Carabaya	0.492	0.287	0.318	0.029	2378.7	10.77	2994
San Antonio de Putina	0.254	0.153	0.150	-0.136	1055.9	5.08	4392
Huancane	0.252	0.164	0.158	-0.133	874.1	7.01	4155
Melgar	0.250	0.157	0.151	-0.130	846.8	5.69	4341
Moho	0.250	0.155	0.148	-0.157	839.2	7.63	4107
Azángaro	0.232	0.158	0.153	-0.128	791.3	6.94	4137
Chucuíto	0.222	0.141	0.136	-0.114	659.3	7.41	4102
Lampa	0.209	0.132	0.128	-0.115	654.0	5.53	4419
Puno	0.204	0.133	0.131	-0.111	739.8	6.30	4224
San Román	0.192	0.126	0.123	-0.120	600.6	7.26	4115
El Collao	0.174	0.112	0.110	-0.108	587.3	5.19	4349
Yunguyo	-0.047	0.021	0.021	0.033	636.5	9.80	3825

La jerarquía provincial evidencia una transición ecológica desde las provincias orientales húmedas hacia las provincias altoandinas. Para la planificación agrícola y ganadera, este patrón implica que los umbrales de interpretación de NDVI no deben aplicarse uniformemente: un valor moderado puede representar un buen estado de pastizal natural en el altiplano, aunque sea bajo en comparación con bosques o coberturas densas de Sandia.

4.4. Relación entre índices y variables locales

Los cuatro índices presentaron asociaciones positivas con precipitación y temperatura y asociaciones negativas con altitud. La precipitación se correlacionó con NDVI ($r = 0.803$), SAVI ($r = 0.807$), EVI ($r = 0.824$ aproximadamente) y NDMI. La temperatura mostró una relación especialmente alta con NDMI ($r = 0.828$), mientras que la altitud se relacionó negativamente con EVI ($r = -0.897$), SAVI ($r = -0.876$) y NDMI ($r = -0.857$).




Figura 4: Matriz de correlación de Pearson entre índices y variables locales.

Estas relaciones son coherentes con el gradiente ecológico regional: a menor altitud se observan temperaturas mayores, precipitaciones más abundantes y vegetación más densa. La fuerte correlación inversa entre temperatura y altitud ($r = -0.967$) confirma que ambas variables capturan dimensiones similares del gradiente topoclimático. Por ello, en modelos explicativos posteriores sería necesario controlar la multicolinealidad, por ejemplo mediante regresión espacial, componentes principales o modelos aditivos generalizados.

4.5. Autocorrelación espacial

Todos los índices mostraron autocorrelación espacial positiva y significativa en cada año [8]. El EVI alcanzó los valores más altos, con un máximo de 0.927 en 2022. El NDMI presentó valores algo menores, entre 0.833 y 0.863, pero igualmente elevados. En todas las pruebas, los valores de p fueron inferiores a 0.05, lo que permitió rechazar la hipótesis de aleatoriedad espacial [6].

Cuadro 5: Índice de Moran global por año e índice. Los valores positivos indican agrupamiento espacial de observaciones semejantes.

Año	NDVI	SAVI	EVI	NDMI
2020	0.898	0.896	0.917	0.833
2021	0.876	0.875	0.904	0.836
2022	0.922	0.912	0.927	0.848
2023	0.914	0.912	0.925	0.863
2024	0.898	0.891	0.914	0.846
2025	0.899	0.897	0.912	0.849




Figura 5: Evolución anual de la autocorrelación espacial global.

Los valores elevados confirman que las observaciones no se distribuyen aleatoriamente. Existen agrupamientos extensos de vegetación alta en la vertiente oriental y agrupamientos de valores bajos en sectores altos y secos. Esta dependencia justifica el empleo de semivariogramas y Kriging [7, 9], y también indica que pruebas estadísticas que ignoren la localización podrían subestimar la incertidumbre.

4.6. Estructura de dependencia espacial del NDVI

El semivariograma experimental de 2025 mostró incremento progresivo de la semivarianza con la distancia. El modelo esférico ajustado presentó un efecto pepita de 0.0016, una meseta aproximada de 0.1213 y un alcance estimado cercano a 500.0 km [17]. El alcance alcanzó el límite superior considerado en el ajuste, lo que refleja un gradiente regional amplio y no únicamente dependencia local de corto alcance.




Figura 6: Semivariograma experimental y modelo esférico ajustado para NDVI en 2025.

El reducido efecto pepita en comparación con la meseta indica que una parte importante de la variación del NDVI posee estructura espacial. Sin embargo, el amplio alcance también puede estar influido por la tendencia altitudinal y climática. En trabajos futuros convendría aplicar Kriging universal o regresión-Kriging incorporando altitud, precipitación y temperatura como covariables para separar tendencia y dependencia residual [9].

4.7. Interpolación mediante Kriging de los índices

El procedimiento de semivariograma, selección del modelo y validación cruzada se ejecutó para NDVI, SAVI, EVI y NDMI, utilizando el paquete `gstat` [16]. Debido a que el NDVI es el indicador de vigor vegetal más utilizado y facilita la interpretación ambiental, se presenta su superficie como resultado cartográfico principal; las superficies de SAVI, EVI y NDMI se generaron con el mismo flujo en RStudio y se conservaron como productos complementarios. La superficie interpolada reproduce un gradiente de valores altos hacia el norte y noreste, asociado principalmente con Sandia y sectores de Carabaya, y valores menores en el centro y sur del altiplano. El mapa ofrece una representación continua, más informativa que una visualización basada únicamente en puntos, y permite detectar transiciones espaciales relevantes para priorizar monitoreo de pastizales, zonas agrícolas y áreas susceptibles a estrés hídrico.




Figura 7: Superficie interpolada mediante Kriging ordinario para el NDVI de 2025. Los puntos negros corresponden a la muestra utilizada para modelar la estructura espacial.

La validación produjo $RMSE=0.082$, $MAE=0.060$, $sesgo=0.002$ y correlación observado-predicho= 0.950 . El sesgo cercano a cero indica ausencia de sobreestimación sistemática importante, mientras que la correlación elevada evidencia capacidad para reproducir el patrón general. Los errores mayores se concentran potencialmente en zonas de transición brusca, donde una superficie suave no representa por completo cambios locales de cobertura.




Figura 8: Relación entre valores observados y predichos durante la validación del Kriging.

4.8. Implicancias ambientales, climatológicas y agrícolas

Desde una perspectiva ambiental, la integración de NDVI, SAVI, EVI y NDMI permite diferenciar vigor vegetal, influencia del suelo y humedad, reduciendo el riesgo de interpretar un único índice de forma aislada. Las provincias orientales muestran condiciones favorables para coberturas densas, mientras que en el altiplano los valores bajos deben evaluarse considerando estacionalidad, tipo de pastizal y altitud.

Desde una perspectiva climatológica, el NDMI y la precipitación son útiles para detectar años o zonas con déficit de humedad. El mínimo regional de NDMI en 2023 sugiere la conveniencia de contrastar estos resultados con registros de sequía, caudales y anomalías climáticas [12], en línea con enfoques que emplean índices de vegetación como indicadores tempranos de condiciones de sequía [19]. La combinación de series más frecuentes, por ejemplo mensuales, permitiría identificar retrasos entre lluvia y respuesta vegetal.

Desde una perspectiva agrícola y ganadera, las superficies interpoladas pueden apoyar la selección de áreas para vigilancia de pastos, planificación de campañas y priorización de asistencia técnica. No obstante, los índices no sustituyen información de campo sobre especie vegetal, biomasa, manejo de suelos, carga ganadera o rendimiento. Su principal utilidad es orientar el muestreo y detectar zonas anómalas que requieren verificación local.

4.9. Limitaciones

El estudio empleó composiciones anuales, por lo que no representa completamente la estacionalidad marcada de Puno. La resolución espacial de CHIRPS y ERA5-Land es más gruesa que la de Sentinel-2 [12, 13, 11], y varios puntos cercanos comparten valores climáticos. La autocorrelación espacial elevada puede reflejar tanto dependencia local como tendencias regionales. Además, la interpolación se ejecutó sobre una muestra para mantener un costo computacional manejable y se delimitó mediante la envolvente de puntos, no mediante un límite administrativo

oficial detallado. Finalmente, las correlaciones representan asociaciones y no demuestran relaciones causales.

5. Conclusiones

La integración de 17 082 observaciones de NDVI, SAVI, EVI y NDMI con precipitación, temperatura y altitud permitió caracterizar la heterogeneidad ambiental de las 13 provincias de Puno durante 2020–2025. El gradiente espacial fue más intenso que la variación interanual: Sandia y Carabaya presentaron las mayores condiciones de vigor vegetal, mientras que varias provincias del altiplano central y sur registraron valores menores.

Los índices se relacionaron positivamente con precipitación y temperatura y negativamente con altitud. El EVI y el SAVI mostraron especial sensibilidad al gradiente topoclimático, mientras que el NDMI aportó información complementaria sobre humedad vegetal. Estas relaciones demuestran la importancia de interpretar los índices junto con variables locales.

La autocorrelación espacial fue alta y significativa en todos los años, justificando el uso de métodos geoestadísticos [8, 7]. Los semivariogramas de NDVI, SAVI, EVI y NDMI permitieron seleccionar entre modelos esférico, exponencial y gaussiano antes de ejecutar el Kriging ordinario [9, 17]. Las superficies resultantes reprodujeron los principales gradientes provinciales. Para el NDVI, presentado como caso principal, la validación alcanzó un RMSE de 0.082 y una correlación de 0.950.

Los resultados pueden apoyar el monitoreo ambiental, la evaluación climatológica y la planificación agrícola y ganadera. Para investigaciones posteriores se recomienda utilizar datos mensuales, límites administrativos oficiales, validación de campo y regresión-Kriging con precipitación, temperatura y altitud como covariables.

Disponibilidad de datos y reproducibilidad

La base analizada contiene datos derivados de Sentinel-2 [11], CHIRPS [12], ERA5-Land [13] y SRTM [14] procesados en Google Earth Engine [20]. El análisis estadístico, la construcción de objetos espaciales, el cálculo de Moran, la comparación de modelos de semivariograma, el Kriging de los cuatro índices, la validación cruzada y la elaboración de figuras se realizaron en RStudio mediante scripts en R, apoyados en los paquetes `sf/spdep` [15] y `gstat` [16]. El archivo tabular, los scripts de R, el código de extracción en Google Earth Engine y las figuras deben conservarse como material suplementario para permitir la reproducción de los resultados.

Declaración ética

El estudio utilizó exclusivamente información geoespacial abierta y agregada. No se emplearon datos personales ni se involucraron participantes humanos; por tanto, no fue necesaria evaluación ética de sujetos humanos.

Contribución de autores

Todos los autores participaron en la definición del problema, preparación de datos, análisis espacial, interpretación y revisión del manuscrito. La versión final fue aprobada por todos los integrantes.

Conflicto de intereses

Los autores declaran no tener conflictos de intereses.

Referencias

- [1] J. W. Rouse, R. H. Haas, J. A. Schell, and D. W. Deering, “Monitoring vegetation systems in the great plains with erts,” in *Third Earth Resources Technology Satellite Symposium*, 1974, pp. 309–317.
- [2] A. R. Huete, “A soil-adjusted vegetation index (savi),” *Remote Sensing of Environment*, vol. 25, no. 3, pp. 295–309, 1988.
- [3] A. Huete, K. Didan, T. Miura, E. P. Rodriguez, X. Gao, and L. G. Ferreira, “Overview of the radiometric and biophysical performance of the MODIS vegetation indices,” *Remote Sensing of Environment*, vol. 83, no. 1–2, pp. 195–213, 2002.
- [4] B.-C. Gao, “NDWI—a normalized difference water index for remote sensing of vegetation liquid water from space,” *Remote Sensing of Environment*, vol. 58, no. 3, pp. 257–266, 1996.
- [5] J. Xue and B. Su, “Significant remote sensing vegetation indices: A review of developments and applications,” *Journal of Sensors*, vol. 2017, p. 1353691, 2017.
- [6] A. D. Cliff and J. K. Ord, *Spatial Processes: Models and Applications*. London: Pion, 1981.
- [7] N. Cressie, *Statistics for Spatial Data*. New York: John Wiley & Sons, 1993.
- [8] P. A. P. Moran, “Notes on continuous stochastic phenomena,” *Biometrika*, vol. 37, no. 1/2, pp. 17–23, 1950.
- [9] P. Goovaerts, *Geostatistics for Natural Resources Evaluation*. New York: Oxford University Press, 1997.
- [10] R. D. Garreaud, M. Vuille, and A. C. Clement, “The climate of the Altiplano: observed current conditions and mechanisms of past changes,” *Palaeogeography, Palaeoclimatology, Palaeoecology*, vol. 194, pp. 5–22, 2003.
- [11] European Space Agency, *Sentinel-2 User Handbook*, European Space Agency, 2015, eSA Standard Document.
- [12] C. Funk, P. Peterson, M. Landsfeld, D. Pedreros, J. Verdin, S. Shukla, G. Husak, J. Rowland, L. Harrison, A. Hoell, and J. Michaelsen, “The climate hazards infrared precipitation with stations—a new environmental record for monitoring extremes,” *Scientific Data*, vol. 2, p. 150066, 2015.
- [13] J. Muñoz-Sabater, “ERA5-Land hourly data from 1981 to present,” 2019.
- [14] T. G. Farr, P. A. Caro, R. Crippen, R. Duren, S. Hensley, M. Kobrick, M. Paller, E. Rodriguez, L. Roth, D. Seal, S. Shaffer, J. Shimada, J. Umland, Y. Zheng, M. Oskin, D. Burbank, and D. Alsdorf, “The shuttle radar topography mission,” *Reviews of Geophysics*, vol. 45, no. 2, p. RG2004, 2007.
- [15] R. S. Bivand, E. Pebesma, and V. Gómez-Rubio, *Applied Spatial Data Analysis with R*, 2nd ed. New York: Springer, 2013.

- [16] E. J. Pebesma, “Multivariable geostatistics in S: the gstat package,” *Computers & Geosciences*, vol. 30, no. 7, pp. 683–691, 2004.
- [17] R. Webster and M. A. Oliver, *Geostatistics for Environmental Scientists*, 2nd ed. Chichester: John Wiley & Sons, 2007.
- [18] T. Hengl, *A Practical Guide to Geostatistical Mapping*, 2nd ed. Luxembourg: Office for Official Publications of the European Communities, 2009.
- [19] F. N. Kogan, “Application of vegetation index and brightness temperature for drought detection,” *Advances in Space Research*, vol. 15, no. 11, pp. 91–100, 1995.
- [20] N. Gorelick, M. Hancher, M. Dixon, S. Ilyushchenko, D. Thau, and R. Moore, “Google Earth Engine: Planetary-scale geospatial analysis for everyone,” *Remote Sensing of Environment*, vol. 202, pp. 18–27, 2017.